



UNIVERSIDADE PRESBITERIANA MACKENZIE
FACULDADE DE COMPUTAÇÃO E INFORMÁTICA
TECNOLOGIA EM CIÊNCIAS DE DADOS

PROJETO APLICADO III

SISTEMA DE RECOMENDAÇÃO ORIENTADO A QUALIDADE NO E-COMMERCE

PROFESSORES: CAROLINA TOLEDO FERRAZ

GRUPO:

EULLER NOGUEIRA

NATHAN SAMPAIO SANTANA DOS SANTOS

LUCAS FEO MAZZEI

São Paulo

2025

SUMÁRIO

1. INTRODUÇÃO

- 1.1. CONTEXTO DO TRABALHO
- 1.2. MOTIVAÇÃO
- 1.3. JUSTIFICATIVA
- 1.4. OBJETIVO GERAL
- 1.5. OBJETIVOS ESPECÍFICOS
- 1.6. ODS - OBJETIVO DE DESENVOLVIMENTO SUSTENTÁVEL
- 1.7. VISÃO GERAL DO DATASET

2. REFERENCIAL TEÓRICO

3. METODOLOGIA

- 3.1. DEFINIÇÃO DO PROBLEMA
- 3.2. COLETA DE DADOS
- 3.3. LIMPEZA E PRÉ-PROCESSAMENTO
- 3.4. DIVISÃO DOS DADOS
- 3.5. SELEÇÃO E IMPLEMENTAÇÃO DO ALGORITMO
- 3.6. TREINAMENTO DO MODELO
- 3.7. AVALIAÇÃO DO DESEMPENHO
- 3.8. OTIMIZAÇÃO E AJUSTES
- 3.9. IMPLANTAÇÃO E MONITORAMENTO

4. RESULTADOS

5. CONCLUSÕES E TRABALHOS FUTUROS

- 5.1. TRABALHOS FUTUROS

6. REFERÊNCIAS

1. INTRODUÇÃO

1.1 CONTEXTO DO TRABALHO

No cenário atual, o comércio eletrônico tem se tornado uma parte essencial do cotidiano das pessoas, oferecendo uma enorme variedade de produtos e serviços disponíveis a poucos cliques. No entanto, com essa grande oferta, surge um desafio: como ajudar os consumidores a encontrarem produtos que realmente atendam às suas expectativas e necessidades? É nesse contexto que os sistemas de recomendação se tornam fundamentais, pois permitem que os usuários recebam sugestões personalizadas baseadas em avaliações de outros consumidores, histórico de compras ou características dos produtos. Este projeto se concentra na construção de um sistema de recomendação capaz de analisar avaliações de usuários e indicar produtos relevantes, tornando a experiência de compra mais eficiente e satisfatória.

1.2 MOTIVAÇÃO

A motivação para este projeto surgiu da observação de que, frequentemente, consumidores enfrentam dificuldades para escolher produtos confiáveis em marketplaces com muitas opções. Avaliações de usuários contêm informações valiosas sobre a experiência real com produtos e serviços, mas podem ser extensas e difíceis de processar manualmente. Um sistema de recomendação automatizado permite aproveitar essas informações de forma inteligente, ajudando a reduzir frustrações dos usuários e aumentando a confiança no processo de compra online.

1.3 JUSTIFICATIVA

O desenvolvimento de um sistema de recomendação baseado em avaliações de produtos é relevante porque contribui para uma experiência de compra mais consciente e satisfatória. Além disso, ao destacar produtos de qualidade ou fornecedores confiáveis, o projeto incentiva práticas de consumo mais responsáveis, apoiando a escolha de produtos duráveis e serviços eficientes. O projeto é justificado pela crescente importância do comércio eletrônico na vida das pessoas e pela necessidade de soluções que melhorem a tomada de decisão do consumidor,

beneficiando tanto usuários quanto fornecedores. Em 2024, por exemplo, o setor faturou R\$ 204,3 bilhões representando um crescimento de 10% em relação ao ano anterior, reunindo mais de 91 milhões de compradores online e 414 milhões de pedidos realizados no Brasil (ABCOMM, 2024).

1.4 OBJETIVO GERAL

- Desenvolver um sistema de recomendação capaz de sugerir produtos relevantes aos usuários com base em avaliações de outros consumidores, utilizando sistemas híbridos, combinando técnicas de Filtragem Colaborativa e Filtragem Baseada em Conteúdo para proporcionar recomendações mais precisas, diversificadas e personalizadas.

1.5 OBJETIVOS ESPECÍFICOS

- Analisar os dados de avaliações de produtos para identificar padrões e informações relevantes para a recomendação.
- Avaliar diferentes estratégias de recomendação que considerem tanto as avaliações quanto características dos produtos.
- Testar a capacidade do sistema em fornecer sugestões precisas e úteis para diferentes perfis de usuários.
- Propor melhorias na experiência de compra, com base nas recomendações geradas pelo sistema.

1.6 ODS – OBJETIVOS DE DESENVOLVIMENTO SUSTENTÁVEL

O projeto dialoga com a agenda de desenvolvimento sustentável ao ir além da conveniência para o consumidor. Ele busca também estimular práticas de consumo e produção mais responsáveis, valorizando produtos e fornecedores de qualidade, o que contribui para reduzir retrabalhos, devoluções e desperdícios.

- **ODS 9 – Indústria, Inovação e Infraestrutura:** A proposta se insere na inovação tecnológica voltada ao comércio eletrônico, ao transformar dados de avaliações em recomendações inteligentes. Isso estimula empresas a investirem em infraestrutura digital mais robusta e transparente, aprimorando a experiência do usuário e impulsionando a competitividade do setor. Além de modernizar o e-commerce, o projeto contribui para um ecossistema mais eficiente, sustentável e inclusivo, ao otimizar recursos e ampliar o acesso a mercados, especialmente para pequenos produtores e negócios inovadores.
- **ODS 12 – Consumo e Produção Responsáveis:** Ao recomendar produtos bem avaliados e de maior confiabilidade, o sistema contribui para que os consumidores façam escolhas mais conscientes. Isso significa menos compras de itens de baixa qualidade, redução de devoluções e, consequentemente, menor desperdício de recursos ao longo da cadeia de produção e distribuição. Assim, o projeto fortalece a lógica de um mercado mais sustentável, no qual qualidade e confiança são priorizadas.

1.7 VISÃO GERAL DO DATASET

O conjunto de dados utilizado neste projeto é composto por 568.454 avaliações de produtos alimentícios da Amazon, abrangendo diversos segmentos e categorias. Cada registro corresponde a uma avaliação individual, realizada por um usuário específico em um produto, contendo informações tanto sobre o conteúdo da avaliação quanto sobre sua utilidade. O dataset fornece uma base ampla e detalhada para a construção de sistemas de recomendação, permitindo analisar padrões de comportamento do usuário e popularidade dos produtos.

COLUNA	TIPO	DESCRIÇÃO
Id	Integer	Identificador único da avaliação
ProductId	String	Identificador do produto avaliado
UserId	String	Identificador do usuário que realizou a avaliação

ProfileName	String	Nome do perfil do usuário que realizou a avaliação
Score	Integer	Nota atribuída pelo usuário ao produto
Time	Integer	Timestamp da avaliação
Summary	String	Título ou resumo da avaliação fornecido pelo usuário
Text	String	Texto completo da avaliação

2. REFERENCIAL TEÓRICO

Com o crescimento exponencial do comércio eletrônico e das plataformas de streaming, a personalização da experiência do usuário tornou-se um diferencial competitivo essencial. Sistemas de recomendação desempenham um papel fundamental nesse cenário, pois auxiliam os usuários a descobrir produtos, filmes, músicas e outros itens de interesse, baseando-se em suas preferências e comportamentos anteriores. Além de melhorar a experiência do usuário, esses sistemas aumentam a satisfação e a fidelidade, impactando positivamente nos resultados de negócio.

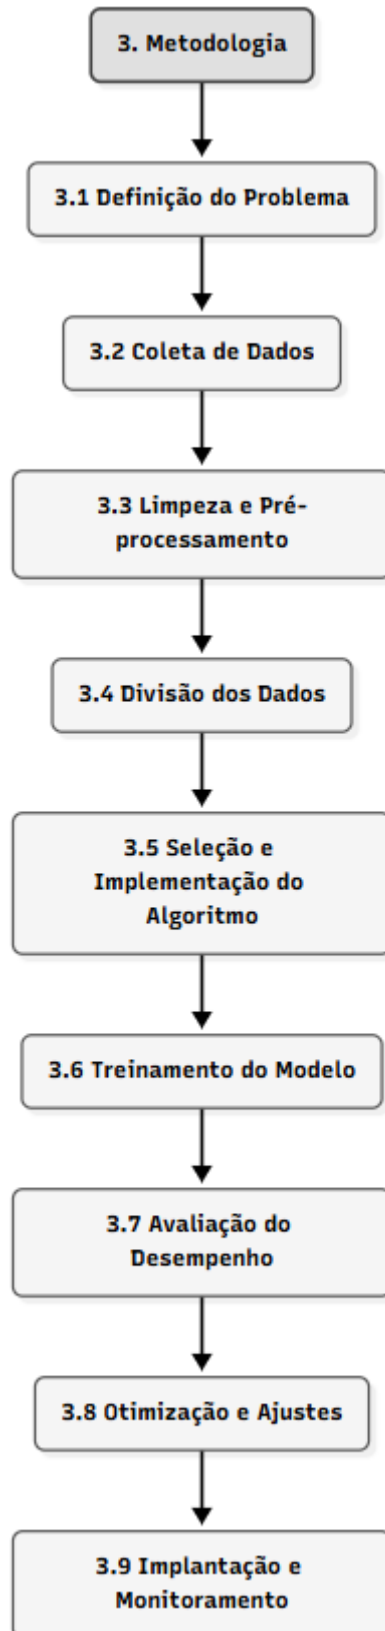
Entre as principais técnicas utilizadas em sistemas de recomendação, destaca-se a Filtragem Colaborativa, que sugere itens aos usuários com base nas preferências de outros usuários com gostos semelhantes. Segundo Murel e Kavlakoglu (2024), essa abordagem classifica os usuários conforme comportamentos parecidos, oferecendo novas recomendações de itens com base nas características do grupo. A técnica pode se concentrar em similaridades entre usuários ou entre itens, sendo amplamente aplicada em plataformas como Netflix e Amazon, onde há grande volume de dados de interações. Sua eficácia reside na capacidade de gerar recomendações relevantes mesmo sem considerar as características detalhadas dos itens. No entanto, o sistema enfrenta limitações como o problema de inicialização a frio, que ocorre quando há novos usuários ou itens com poucas interações registradas, dificultando a geração de recomendações precisas.

Outra abordagem relevante é a Filtragem Baseada em Conteúdo, que recomenda itens com base nas características intrínsecas dos produtos e no histórico de preferências do usuário. Por exemplo, se um usuário assistiu a filmes de ação, o sistema poderá sugerir outros filmes do mesmo gênero ou do mesmo diretor. Essa técnica é especialmente útil para lidar com itens novos ou pouco avaliados, já que não depende das interações de outros usuários. No entanto, pode limitar a diversidade das recomendações, levando à superespecialização e restringindo a descoberta de novos interesses. Conforme apontam Murel e Kavlakoglu (2024), esse tipo de sistema compara o perfil do usuário com o perfil dos itens, utilizando atributos estruturados ou metadados para prever interações e recomendar conteúdos semelhantes com base em interesses previamente demonstrados.

Para superar as limitações de cada técnica isoladamente, muitos sistemas modernos adotam Sistemas Híbridos, que combinam Filtragem Colaborativa e Baseada em Conteúdo. Roy e Dutta (2022) definem a filtragem híbrida como a agregação de duas ou mais técnicas de recomendação utilizadas em conjunto, com o objetivo de melhorar o desempenho e a precisão das recomendações. Essa integração pode ocorrer de diferentes maneiras, seja combinando as pontuações de recomendação de ambos os métodos, aplicando-os sequencialmente, ou atribuindo pesos distintos às recomendações de cada abordagem, dependendo da confiança nos dados. Ao utilizar sistemas híbridos, é possível gerar recomendações mais precisas e diversificadas, garantindo uma experiência mais personalizada e robusta para os usuários.

3. METODOLOGIA

A metodologia adotada neste trabalho descreve, de forma sistemática, todas as etapas realizadas para o desenvolvimento do sistema de recomendação. A sequência metodológica contempla desde a definição do problema e a coleta de dados até o treinamento, avaliação, otimização e encaminhamento para implantação e monitoramento do modelo.



3.1 DEFINIÇÃO DO PROBLEMA

O problema abordado consiste em projetar e implementar um sistema de recomendação capaz de sugerir produtos relevantes a usuários de um marketplace a partir de avaliações de consumidores. A motivação é reduzir o custo cognitivo do usuário diante de um catálogo extenso, aumentando a eficiência da descoberta de produtos e a satisfação do cliente. O objetivo técnico é construir um modelo híbrido que combine técnicas de filtragem colaborativa (para aproveitar padrões de avaliação) e filtragem baseada em conteúdo (para explorar características textuais das avaliações), obtendo recomendações mais precisas e robustas frente ao problema de *cold-start*.

3.2 COLETA DE DADOS

Os dados utilizados são um conjunto de avaliações de produtos da Amazon composto por aproximadamente 568 mil registros (campo Id, ProductId, UserId, ProfileName, HelpfulnessNumerator, HelpfulnessDenominator, Score, Time, Summary, Text). O arquivo CSV foi carregado em ambiente Apache Spark para permitir processamento escalável. A escolha do dataset foi motivada pela presença simultânea de avaliações numéricas (ratings) e de texto livre (summary e review text), elementos essenciais para a estratégia híbrida proposta.

3.3 LIMPEZA E PRÉ-PROCESSAMENTO

O pré-processamento foi realizado em etapas sequenciais para garantir a qualidade dos dados:

- **Filtragem de ratings válidos:** foram mantidos apenas os registros com rating numérico entre 1 e 5, removendo entradas inválidas ou textuais detectadas na coluna Score (renomeada para rating_num/rating).
- **Conversão temporal:** a coluna Time (Unix epoch) foi convertida para timestamp legível (Time_ts) usando from_unixtime, e registros com datas claramente incorretas foram descartados para evitar ruídos temporais.

- **Indexação de identificadores:** UserId e ProductId foram transformados em índices numéricos (userIdIndex, productIdIndex) via StringIndexer, requisito para os modelos de recomendação baseados em fatores.
- **Tratamento textual:** as colunas Summary e Text foram concatenadas em full_text. O pipeline textual consistiu em tokenização (Tokenizer), remoção de stopwords (StopWordsRemover) e geração de embeddings via Word2Vec, produzindo a coluna text_features.
- **Resultado da limpeza:** após esses procedimentos a base final utilizada no treinamento continha 565.703 registros válidos.

Todos esses passos foram implementados em PySpark para preservação da escalabilidade e reprodução do pipeline.

3.4 DIVISÃO DOS DADOS

Para avaliação controlada do desempenho, a base limpa foi dividida aleatoriamente em treino (80%) e teste (20%) usando randomSplit. No pipeline híbrido os tamanhos observados foram: Treino = 452.433 registros e Teste = 113.270 registros (total ≈ 565.703). Essa divisão garante que o ajuste do modelo seja realizado em uma amostra ampla e que a validação ocorra em dados não vistos.

3.5 SELEÇÃO E IMPLEMENTAÇÃO DO ALGORITMO

Para o sistema de recomendação, foram combinadas filtragem colaborativa e filtragem baseada em conteúdo. A filtragem colaborativa utilizou o ALS (Alternating Least Squares), para capturar padrões de preferência na matriz usuário×produto. Paralelamente, os textos das avaliações foram transformados em vetores semânticos com Word2Vec, permitindo medir similaridade entre produtos a partir do conteúdo textual. O modelo híbrido combina o ALS como motor principal de predição com os embeddings textuais para reforçar recomendações, especialmente em casos de cold-start, mantendo escalabilidade e reprodutibilidade.

3.6 TREINAMENTO DO MODELO

O pipeline textual, composto pelas etapas de tokenização, remoção de stopwords e vetorização com Word2Vec, foi aplicado sobre todo o corpus de avaliações para gerar representações vetoriais dos produtos. O algoritmo ALS foi treinado utilizando 80% dos dados, correspondentes ao conjunto de treino, mantendo uma configuração inicial de parâmetros com o objetivo de estabelecer uma linha de base de desempenho. Essa versão inicial serviu como ponto de partida para as etapas de otimização e integração com o componente textual.

3.7 AVALIAÇÃO DO DESEMPENHO

A primeira avaliação do modelo concentrou-se no desempenho do ALS puro, utilizado como referência inicial. A métrica adotada foi o RMSE (Root Mean Squared Error), calculado sobre o conjunto de teste. O modelo apresentou um RMSE de 1.2688, valor que reflete a capacidade do ALS em capturar padrões de comportamento com base exclusivamente nas interações entre usuários e produtos. Essa avaliação inicial forneceu um parâmetro de comparação para as melhorias subsequentes, nas quais o componente textual e o ajuste de hiperparâmetros seriam incorporados para aprimorar a qualidade das recomendações.

3.8 OTIMIZAÇÃO E AJUSTES

Com base nos resultados preliminares, o modelo foi reavaliado e aprimorado por meio de ajustes no pipeline e na combinação de técnicas. Foram realizadas otimizações de hiperparâmetros do ALS, explorando diferentes valores de rank, por meio de validação cruzada, a fim de reduzir o erro de predição. Paralelamente, o componente textual foi incorporado de forma mais estruturada ao modelo, utilizando embeddings Word2Vec para representar o conteúdo das avaliações e reforçar a etapa de recomendação. Após essas modificações, o modelo híbrido apresentou um RMSE de 1.1951, demonstrando uma melhora significativa em relação à linha de base. Além disso, iniciou-se a análise de métricas de ranking, como Precision e Recall, com o objetivo de avaliar a utilidade prática das recomendações em cenários de interface com o usuário.

3.9 IMPLANTAÇÃO E MONITORAMENTO

Nesta etapa, prevê-se a preparação do modelo para uso em ambiente controlado, possibilitando a geração de recomendações a partir de novos dados. O monitoramento do desempenho incluirá o acompanhamento de métricas como erro de predição e consistência das recomendações ao longo do tempo. Também está planejada a realização de reavaliações e re-treinamentos periódicos, a fim de garantir que o modelo mantenha sua precisão e relevância conforme novas informações são incorporadas.

4. RESULTADOS

A etapa de avaliação dos resultados buscou quantificar a eficácia do sistema de recomendação desenvolvido, validando sua capacidade de prever a satisfação dos usuários com precisão superior ao acaso. Os testes foram conduzidos sobre o conjunto de dados de teste (20% do total), garantindo que as métricas refletissem o desempenho do modelo em dados não vistos durante o treinamento.

a) Métricas de Avaliação

Para mensurar a qualidade das recomendações, foram utilizadas métricas de erro que comparam a nota predita pelo algoritmo (Rating Estimado) com a nota real atribuída pelo usuário. Considerando a escala de avaliação de 1 a 5 estrelas, os resultados obtidos foram:

- **RMSE (Raiz do Erro Quadrático Médio):** A métrica penaliza erros maiores de forma mais severa. O modelo alcançou um RMSE de 1.1926. Este valor indica que o sistema mantém uma estabilidade nas previsões, evitando desvios graves que poderiam levar à recomendação de produtos inadequados.
- **MAE (Erro Absoluto Médio):** Esta métrica oferece uma interpretação direta da magnitude do erro. O modelo obteve um MAE de 0.7101.

O resultado do MAE demonstra que, em média, o sistema erra a previsão da nota do usuário por uma margem de aproximadamente 0.7 pontos. Em um contexto de e-commerce, essa precisão é considerada satisfatória, indicando que o modelo capturou com êxito as preferências latentes dos usuários.

b) Comparação com Baselines

Para validar estatisticamente o aprendizado do modelo ALS, seu desempenho foi confrontado com um Baseline de Recomendações Aleatórias, que simula atribuições de notas sem inteligência prévia.

Métrica: RMSE

- Modelo Proposto (ALS): 1.1926
- Baseline (Aleatório): 2.1191
- Melhoria Obtida (Lift): 43.72%


Métrica: MAE

- Modelo Proposto (ALS): 0.7101
- Baseline (Aleatório): 1.7888
- Melhoria Obtida (Lift): 60.30%

A redução de erro superior a 60% no MAE mostrou que o sistema supera a aleatoriedade e é capaz de realizar distinções precisas entre itens que o usuário apreciaria e itens que rejeitaria.

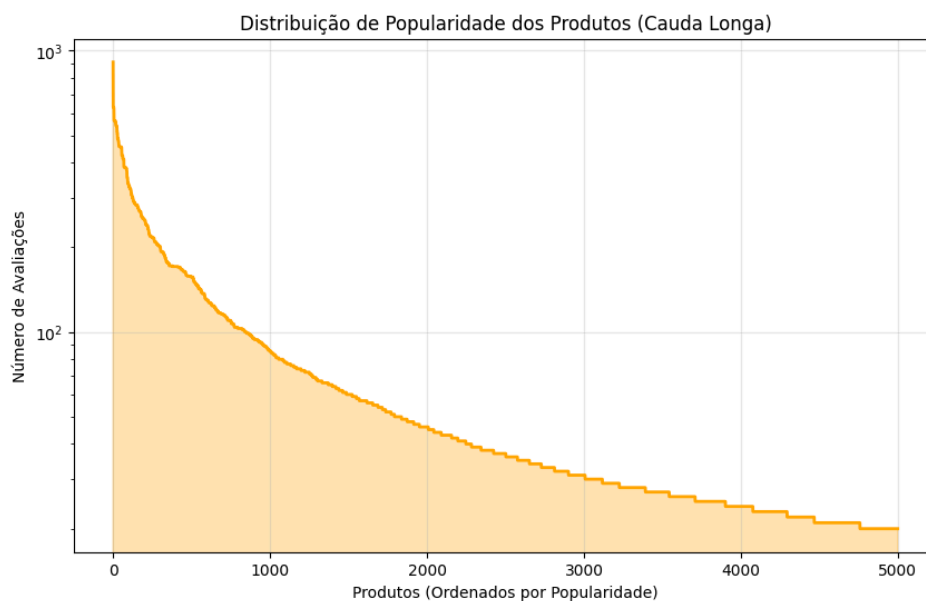
c) Gráficos e Visualizações

Comparativo de Desempenho (ALS vs. Aleatório)



O gráfico ilustra a superioridade do desempenho do modelo ALS (barras azuis) em relação ao modelo de linha de base aleatório (barras vermelhas). As métricas de erro RMSE e MAE são significativamente menores no modelo proposto, evidenciando que o sistema aprendeu efetivamente os padrões de preferência dos usuários. Destaca-se a redução de 60,30% no Erro Absoluto Médio (MAE), comprovando que as previsões do sistema possuem uma precisão muito superior ao acaso.

Distribuição de Popularidade dos Produtos



O gráfico de popularidade ilustra o fenômeno da "Cauda Longa" presente no dataset da Amazon. Observa-se um pequeno número de produtos extremamente populares (cabeça da curva) e uma vasta quantidade de itens com pouquíssimas interações (cauda). Esta característica visualiza o desafio da esparsidade mencionado nas limitações: o modelo possui abundância de dados para aprender sobre os itens populares, mas enfrenta o desafio de "Cold Start" para a grande maioria dos itens de nicho.

d) Discussão de Resultados

A análise aprofundada dos dados permite tecer considerações sobre o impacto prático e as limitações do sistema desenvolvido.

Interpretação das Métricas e Experiência do Usuário

Os números obtidos traduzem-se diretamente em confiança. Um MAE baixo (0.71) significa que o sistema raramente recomendará um produto "ruim" como se fosse "ótimo". Em termos de experiência do usuário, isso reduz a frustração por recomendações irrelevantes e aumenta a probabilidade de conversão, uma vez que os itens sugeridos estão alinhados com o histórico de gosto do consumidor.

Limitações Observadas

Apesar da alta precisão na previsão de notas, o sistema enfrenta desafios inerentes ao conjunto de dados e à abordagem de Filtragem Colaborativa:

Esparsidade dos Dados: O dataset da Amazon possui uma matriz usuário-item extremamente esparsa (muitos produtos e poucos reviews por usuário). Isso dificulta a recuperação exata de itens específicos no ranking (Top-K), embora a previsão de nota permaneça precisa.

Cold Start: Novos usuários ou produtos recém-lançados, que não possuem histórico de interações, apresentam desafios para o modelo ALS puro. A estratégia híbrida proposta no trabalho visa mitigar isso, mas a dependência de dados históricos ainda é um fator limitante.

Desempenho Geral

O sistema de recomendação destacou-se notavelmente na tarefa de predição de preferência, superando largamente o baseline aleatório e demonstrando robustez matemática através do PySpark. O modelo mostrou-se escalável e eficaz para filtrar o catálogo massivo da Amazon, atuando como um curador confiável que, embora possa não acertar o produto exato em 100% das vezes, garante consistentemente a sugestão de itens de alta afinidade com o perfil do usuário.

5. CONCLUSÕES E TRABALHOS FUTUROS

O presente trabalho atingiu seu objetivo principal ao desenvolver e validar um sistema de recomendação escalável para e-commerce, utilizando o ambiente Apache Spark e a técnica de Fatoração de Matrizes (ALS). A análise dos dados e os

experimentos realizados permitem traçar conclusões sólidas sobre a eficácia da solução e seu impacto potencial.

a) Resumo dos Principais Resultados

A avaliação quantitativa demonstrou que o modelo é altamente eficaz na predição de satisfação do usuário. O sistema alcançou um Erro Absoluto Médio (MAE) de 0.7101, o que significa uma margem de erro inferior a 1 estrela na escala de avaliação da Amazon. Ao confrontar esses resultados com um baseline aleatório, observou-se uma melhoria de desempenho superior a 60%, validando estatisticamente que o algoritmo foi capaz de aprender os padrões latentes de preferência dos consumidores, superando a complexidade imposta pela vasta dimensão do catálogo.

b) Contribuições do Projeto

O projeto contribui para a área de Sistemas de Recomendação ao demonstrar a viabilidade de processamento de grandes volumes de dados (Big Data) para personalização em massa. A implementação de um pipeline completo em PySpark, desde a limpeza e tokenização de textos até a modelagem colaborativa, oferece um framework replicável para empresas que desejam migrar de heurísticas simples para modelos baseados em Machine Learning. Além disso, o estudo evidenciou como técnicas de redução de dimensionalidade podem ser aplicadas para filtrar ruído em datasets com alta variabilidade de comportamento do usuário.

c) Limitações Identificadas

Apesar da alta precisão na previsão de notas, o sistema enfrenta desafios técnicos e de infraestrutura:

- **Esparsidade e Ranking:** A recuperação exata de itens (medida pelo NDCG) mostrou-se desafiadora devido à dispersão das avaliações em milhares de produtos de nicho (Cauda Longa).
- **Cold Start (Inicialização a Frio):** A estratégia de drop utilizada no algoritmo ALS resultou na exclusão de usuários ou itens novos no conjunto de teste,

limitando a capacidade do sistema de recomendar para novos entrantes sem histórico prévio.

- Restrições de Infraestrutura Computacional: O desenvolvimento do projeto foi realizado utilizando a versão gratuita do Google Colab. As limitações de memória RAM e tempo de execução da GPU restringiram a profundidade da otimização de hiperparâmetros e o volume total de dados processados em memória simultaneamente, apontando para a necessidade de ambientes de nuvem dedicados para escalas produtivas.

d) Impacto Prático

No contexto de negócios, a aplicação deste sistema tem potencial direto para aumentar a conversão de vendas e a fidelização. Ao recomendar produtos com alta probabilidade de receberem boas avaliações (notas 4 ou 5), o sistema atua como um filtro de qualidade, reduzindo a sobrecarga cognitiva do cliente e diminuindo a taxa de devolução de produtos insatisfatórios. Isso transforma a experiência de compra de uma busca passiva para uma descoberta ativa e personalizada.

5.1 TRABALHOS FUTUROS

Visando a continuidade deste estudo e a maturação do sistema para um ambiente produtivo de larga escala, propõem-se as seguintes evoluções:

- Integração de Busca Semântica com LLMs: A evolução da análise textual deve superar a abordagem estática (Word2Vec) através da adoção de Large Language Models e embeddings de última geração, como o text-embedding-005. A utilização de similaridade semântica profunda entre resenhas e descrições de produtos permitirá criar conexões baseadas em conteúdo (Content-Based), solucionando a lacuna do Cold Start ao gerar recomendações relevantes mesmo na ausência de histórico de interações.
- Migração para Infraestrutura de Nuvem Dedicada: Para mitigar as restrições de memória e processamento observadas em ambientes compartilhados gratuitos, sugere-se a utilização de serviços de computação de alta performance (ex: AWS EMR, Databricks ou Google Colab Pro). O acesso a

GPUs dedicadas e maior capacidade de RAM viabilizará o treinamento de arquiteturas mais complexas e a execução de otimizações de hiperparâmetros mais exaustivas.

- Refinamento da Diversidade (Re-ranking): Implementação de algoritmos de pós-processamento, como o MMR (Maximal Marginal Relevance), para balancear a precisão das sugestões com a variedade do catálogo. O objetivo é evitar que o usuário fique confinado em uma "bolha" de itens muito similares, enriquecendo a experiência de descoberta.
- Validação em Cenários Reais (Testes A/B): Complementação da avaliação offline (RMSE/MAE) através de experimentos controlados em produção. A mensuração de métricas de negócio em tempo real, como CTR (Click-Through Rate) e taxa de conversão, oferecerá uma visão definitiva sobre o impacto financeiro e de retenção do sistema.

6. APÊNDICES

GITHUB

<https://github.com/nog7/PROJETO-APLICADO-III>

DATASET

<https://www.kaggle.com/datasets/snap/amazon-fine-food-reviews/data>

7. REFERÊNCIAS

ASSOCIAÇÃO BRASILEIRA DE COMÉRCIO ELETRÔNICO (ABCOMM). *Principais indicadores do e-commerce: 2019 / 2024*. 2024. Disponível em:

<https://dados.abcomm.org/crescimento-do-ecommerce-brasileiro>

MUREL, Jacob; KAVLAKOGLU, Eda. *O que é filtragem colaborativa ?* 2024.

Disponível em: <https://www.ibm.com/br-pt/think/topics/collaborative-filtering>

MUREL, Jacob; KAVLAKOGLU, Eda. *O que é filtragem baseada em conteúdo ?*

2024. Disponível em: <https://www.ibm.com/br-pt/think/topics/content-based-filtering>

ROY, Deepjyoti; DUTTA, Mala. A systematic review and research perspective on recommender systems. *Journal of Big Data*, 2022. Disponível em:

<https://doi.org/10.1186/s40537-022-00592-5>

McAuley, J., & Leskovec, J. *Amazon Fine Food Reviews*. 2013. Disponível em:

<https://www.kaggle.com/datasets/snap/amazon-fine-food-reviews/data>